Bases de Datos

Tema: Teoría de diseño de Bases de Datos Relacionales (II)

Bibliografía

- Ramez A. Elmasri, Shamkant B. Navathe. Fundamentos de Sistemas de Bases de Datos (5º edic.). Prentice-Hall. 2007 [cap. 10]
- De Miguel, A., Piattini. Fundamentos y modelos de bases de datos (2ª edic.)., Rama. [cap. 8]
- A. Silberschatz, Korth, Sudarshan. Fundamentos de Bases de Datos (5^a edic.). McGraw-Hill [cap. 7]

5.9. Introducción a la Normalización

Ejemplo de diseño inadecuado

ESCRIBE

<u>AUTOR</u>	NACIONALIDAD	COD_LIBRO	TITULO	EDITORIAL	AÑO
Date, C.	Norteamericana	23433	Databases	Adisson-W.	1990
Date, C.	Norteamericana	54654	SQL Standard	Adisson-W.	1986
Date, C.	Norteamericana	53235	Guide To Ingres	Adisson-W.	1988
Codd, E.	Norteamericana	97875	Relational M.	Adisson-W.	1990
Gardarin	Francesa	34245	Base de Datos	Paraninfo	1986
Gardarin	Francesa	55366	Comparación BD	Eyrolles	1984
Valduriez	Francesa	86754	Comparación BD	Eyrolles	1984
Kim, W.	Norteamericana	32176	OO Databases	ACM Press	1989
Lochovsky	Canadiene	23456	OO Databases	ACM Press	1989

PROBLEMAS:

- Redundancia
- Anomalías (de inserción, borrado y modificación)

5.9. Introducción a la Normalización

- La normalización de datos puede considerarse un proceso de análisis de los esquemas de relación basándose en sus DFs y claves para alcanzar las propiedades deseables de:
 - minimizar la redundancia
 - minimizar las anomalías de inserción, eliminación y actualización
- El proceso de normalización proporciona a los diseñadores los siguientes aspectos:
 - un marco formal para analizar las relaciones basándose en sus claves y en las DF entre atributos.
 - una serie de pruebas que pueden efectuarse sobre relaciones individuales de modo que la BD relacional pueda normalizarse hasta el grado deseado (1FN, 2FN, 3FN, FNBC).

5.10. Descomposición en esquemas

- El proceso de normalización por descomposición parte de la relación universal (relación compuesta por todos los atributos) descomponiéndola en subrelaciones sin anomalías.
- Dado un esquema R(T, L), donde T={A₁, A₂, ..., A_n}, una descomposición de R es la sustitución de R por un conjunto de relaciones R₁, R₂, ..., R_k, tales que:
 - $\blacksquare R_i = \prod_{A1, A2, ...Aj} (R)$
 - $R_1 \propto R_2 \propto ... \propto R_k$ da lugar al **mismo esquema** de R y la **unión de sus atributos** es A_1 , A_2 , ..., A_n , es decir, el conjunto de atributos del esquema inicial.

5.10. Descomposición en esquemas

→ Ejemplo

Posible descomposición para la relación LIBRO

LIBRO

COD_LIBRO	EDITORIAL	PAIS
654654	Ra-Ma	España
665465	Ra-Ma	España
876545	Paraninfo	España
987456	Anaya	España
965842	Addison-w.	EEUU

LIBRO1

COD_LIBRO	PAIS
654654	España
665465	España
876545	España
987456	España
965842	EEUU

EDITORIAL1

EDITORIAL	PAIS
Ra-Ma	España
Paraninfo	España
Anaya	España
Addison-w.	EEUU

□ La descomposición anterior presenta *problemas*:

EDITORIAL1

COD_LIBRO	PAIS
654654	España
665465	España
876545	España
987456	España
965842	EEUU



EDITORIALI	
EDITORIAL	PAIS
Ra-Ma	España
Paraninfo	España
Anaya	España
Addison-w.	EEUU

COD_LIBRO	EDITORIAL	PAIS	
654654	Ra-Ma	España	
654654	Paraninfo	España	
654654	Anaya	España	
665465	Ra-Ma	España	Tunlas
665465	Paraninfo	España	Tuplas Espurias
665465	Anaya	España	Espurias
876545	Ra-Ma	España	
876545	Paraninfo	España	
876545	Anaya	España	

- En el proceso de normalización **por descomposición** debe comprobar, no sólo que cada relación esté en una determinada forma normal (1FN, 2FN, 3FN), además cada una de las relaciones obtenidas por descomposición deberá cumplir una serie de propiedades, en concreto:
 - Unión sin pérdida: Garantiza que se obtengan las mismas instancias de la relación original a partir de las subrelaciones.
 - 2. Preservación de atributos: Todo atributo de la relación original R deberán aparecer al menos en una relación Ri de la descomposicón.
 - 3. **Preservación de dependencias**: Las mismas restricciones que existían en la relación original deben existir sobre las subrelaciones.
- Si una descomposición cumple estas tres propiedades, se dice que es una DESCOMPOSICIÓN SIN PÉRDIDA.

- En el proceso de normalización por descomposición debe comprobar que cada una de las relaciones obtenidas por descomposición cumpla una serie de propiedades, entre ellas, la de unión sin pérdida:
 - Sea \mathbf{R} un esquema relación que se descompone en los esquemas $R_1,...R_k$, y \mathbf{L} un conjunto de dependencias funcionales
 - La descomposición tiene la propiedad de unión sin pérdida de información respecto de L, es decir es join sin pérdida (lossless join, LJ), si para toda ocurrencia r del esquema R, r(R)

```
\mathbf{r} = \prod_{\mathsf{T1}}(\mathbf{r}) \otimes \prod_{\mathsf{T2}}(\mathbf{r}) \otimes ... \otimes \prod_{\mathsf{Tk}}(\mathbf{r})
```

- Es decir, cada relación r se reconstruye como el join natural de sus proyecciones sobre cada R_i .
- En caso de que una descomposición no posea esta propiedad, es posible que surjan tuplas espurias.

En el caso de la relación LIBRO, se podría haber descompuesto en los siguientes esquemas:

```
LIBRO2 (COD_LIBRO, PAIS)
EDITORIAL2 (COD_LIBRO, EDITORIAL)
```

- En este caso, LIBRO= LIBRO2 ∞ EDITORIAL2.
 - NO aparecen tuplas espurias.
- La condición necesaria y suficiente para que una descomposición se produzca sin pérdida de información es que el atributo común de las dos relaciones sea clave, al menos, en una de ellas.

→ Algoritmo

Sea una descomposición de R (T, L) con:

T={A₁, A₂,..., A_m}
L={x
$$\rightarrow$$
 y / x \cup y \subseteq T}
 ρ = {R₁,..., R_k}.

- Para verificar el cumplimiento de la propiedad LJ en la descomposición ρ se va a utilizar el siguiente algoritmo:
 - Construir matriz con \mathbf{m} columnas (una por cada atributo $\mathbf{A_j}$) y \mathbf{k} filas (una por cada esquema de relación $\mathbf{R_i}$)
 - Colocar en la fila i columna j la letra $\mathbf{a_j}$ si $\mathbf{A_j}$ está en $\mathbf{R_i}$, sino colocar $\mathbf{b_{ij}}$.
 - 3. Considerar ahora cada una de las dependencias de L.
 - Si para X→Y se encuentran dos filas que coincidan las entradas correspondientes a X, se igualan las correspondientes a Y:
 - si el símbolo es a_i, lo hacemos a_i
 - si ambos son **b**, igualamos los subíndices de cualquiera de ellos a los del otro.
 - Si se encuentra una fila llena de a's, la descomposición verifica la propiedad LJ y no la verifica en caso contrario.

→ Ejemplo

- \square R(T, L), tal que:
 - T = {A, B, C, D, E} L = {A \rightarrow C, B \rightarrow C, C \rightarrow D, DE \rightarrow C, CE \rightarrow A} ρ = {AD, AB, BE, CDE, AE}
 - Paso 1: Construir matriz con m columnas (una por cada atributo A_j) y k filas (una por cada esquema de relación R_i)

	Α	В	С	D	E
AD					
AB					
BE					
CDE					
AE					

→ Ejemplo

```
R(T, L), tal que: T = \{A, B, C, D, E\} L = \{A \rightarrow C, B \rightarrow C, C \rightarrow D, DE \rightarrow C, CE \rightarrow A\} \rho = \{AD, AB, BE, CDE, AE\}
```

Paso 2: Colocar en la fila i columna j la letra a_j si A_j está en R_i, sino colocar b_{ii}.

	Α	В	С	D	E
AD	a1	b12	b13	a4	b15
AB	a1	a2	b23	b24	b25
BE	b31	a2	b33	b34	а5
CDE	b41	b42	а3	a4	а5
AE	a1	b52	b53	b54	а5

→ Ejemplo

```
R(T, L), tal que: T = \{A, B, C, D, E\} L = \{A \rightarrow C, B \rightarrow C, C \rightarrow D, DE \rightarrow C, CE \rightarrow A\} \rho = \{AD, AB, BE, CDE, AE\}
```

- Paso 3: Considerar ahora cada una de las dependencias de L.
 - Si para X→Y se encuentran dos filas que coincidan las entradas correspondientes a X, se igualan las correspondientes a Y:
 - si el símbolo es a_i, lo hacemos a_i
 - si ambos son b, igualamos los subíndices de cualquiera de ellos a los del otro.

	Α	В	С	D	E
AD	a1	b12	b13	a4	b15
AB	a1	a2	b23	b24	b25
BE	b31	a2	b33	b34	а5
CDE	b41	b42	аЗ	a4	а5
AE	a1	b52	b53	b54	а5

 $A \rightarrow C$

	Α	В	С	D	E
AD	a1	b12	b13	a4	b15
AB	a1	a2	b23	b24	b25
BE	b31	a2	b33	b34	а5
CDE	b41	b42	аЗ	a4	а5
AE	a1	b52	b53	b54	а5

→ Ejemplo

A→C	A	В	С	D	E
AD	a ₁	b ₁₂	b ₁₃	a ₄	b ₁₅
AB	a ₁	a_2	b ₁₃	b ₂₄	b ₂₅
BE	b ₃₁	a_2	b ₃₃	b ₃₄	a ₅
CDE	b ₄₁	b ₄₂	a_3	a ₄	a ₅
AE	a ₁	b ₅₂	b ₁₃	b ₅₄	a ₅
C→D	Α	В	С	D	E
C→D AD	A a ₁	B b ₁₂	C b ₁₃	D a ₄	E b ₁₅
_					
AD	a ₁	b ₁₂	b ₁₃	a ₄	b ₁₅
AD AB	a ₁	b ₁₂	b ₁₃	a ₄	b ₁₅

R(T, L), tal que:

$$T = \{A, B, C, D, E\}$$

$$L = \{A \rightarrow C, B \rightarrow C, C \rightarrow D, DE \rightarrow C, CE \rightarrow A\}$$

$$\rho = \{AD, AB, BE, CDE, AE\}$$

B→C	Α	В	С	D	E
AD	a ₁	b ₁₂	b ₁₃	a ₄	b ₁₅
AB	a ₁	a ₂	b ₁₃	b ₂₄	b ₂₅
BE	b ₃₁	a ₂	p (33)	b ₃₄	a ₅
CDE	b ₄₁	b ₄₂	a_3	a ₄	a ₅
AE	a ₁	b ₅₂	b ₁₃	b ₅₄	a ₅

DE→C	Α	В	С	D	E
AD	a ₁	b ₁₂	b ₁₃	a ₄	b ₁₅
AB	a ₁	a_2	b ₁₃	a ₄	b ₂₅
BE	b ₃₁	a ₂	b ₃₃	a ₄	a ₅
CDE	b ₄₁	b ₄₂	a ₃	a ₄	a ₅
AE	a ₁	b ₅₂	b ₃₃	a ₄	a ₅

→ Ejemplo

R(T, L), tal que: $T = \{A, B, C, D, E\}$ $L = \{A \rightarrow C, B \rightarrow C, C \rightarrow D, DE \rightarrow C, CE \rightarrow A\}$ $\rho = \{AD, AB, BE, CDE, AE\}$

Paso 3:

CE→A	A	В	С	D	E
AD	a ₁	b ₁₂	b ₁₃	a ₄	b ₁₅
AB	a ₁	a ₂	b ₁₃	a ₄	b ₂₅
BE	a ₃₁	a ₂	a_3	a ₄	a ₅
CDE	b ₄₁	b ₄₂	a_3	a ₄	a ₅
AE	a ₁	b ₅₂	a ₃	a ₄	a ₅

- Paso 4: Si se encuentra una fila llena de a's, la descomposición verifica la propiedad LJ y no la verifica en caso contrario.
 - La tercera fila es (a1, a2, a3, a4, a5), así que la descomposición **verifica la propiedad LJ**, pudiendo por tanto reconstruirse cualquier ocurrencia r del esquema R a partir de la unión natural de sus proyecciones.

→ Ejemplo

- \blacksquare R(T, L), tal que:
 - T = {NSS, NOMBREE, NUMEROP, NOMBREP, LOCALIZACIONP, HORAS}
 L = {NSS → NOMBREE; NUMEROP → NOMBREP, LOCALIZACIONP;
 NSS, NUMEROP→HORAS}
 ρ = {R1, R2, R3}
 R1= EMP= {NSS, NOMBREE}
 R2= PROYECTO= {NUMEROP, NOMBREP, LOCALIZACIONOP}
 R3= TRABAJA_EN= {NSS, NUMEROP, HORAS}

→ Teorema

Teorema: R_1 , R_2 es una descomposición join sin pérdida de R con respecto al conjunto de dependencias funcionales L si y sólo si vale, por lo menos, alguna de las siguientes dependencias de L^+

$$(T_1 \cap T_2) \rightarrow T_1 - T_2$$
, o bien $(T_1 \cap T_2) \rightarrow T_2 - T_1$

Esto quiere decir que para que una descomposición de R en $\frac{2 \text{ subrelaciones}}{2 \text{ subrelaciones}}$ R₁ y R₂ se produzca sin pérdida de información es necesario que **el atributo o atributos comunes** de las dos relaciones **sea(n) clave en alguna de ellas**.

<u>Ejemplo</u>: Sea el siguiente conjunto de DF's

$$Id\# \rightarrow Nombre, Dirección$$

 $C\# \rightarrow Descripción$
 $Id\#, C\# \rightarrow Grado$

 \bullet ¿es $R_1(Id#, Nombre, Dirección) y <math>R_2(Id#, C#, Descripción, Grado)$ una descomposición con la propiedad de join sin pérdida (LJ)?

- Otra propiedad deseable de la descomposición de un esquema de relación $\rho=(R_1, ..., R_n)$ es la de **preservación de las dependencias**. Es decir, que las **DF's originales se mantengan**, ya que éstas recogen la semántica del mundo real, las restricciones que ha de cumplir la base de datos.
- No será necesario que las DF's **exactas** especificadas en la relación original aparezcan en las relaciones individuales de la descomposición. Basta con que la **unión de las DF's** que se cumplen en las relaciones individuales **sea equivalente** al conjunto de DF's de la relación original. Es decir, que cada DF del esquema original aparezca directamente en uno de los esquemas R_i, o bien, pueda inferirse de las DF's que aparecen en algún R_i.

¿Cómo saber qué DF's le corresponden a cada Ri tras realizar la descomposición?

Dado un conj. L de DF's sobre R, las DF's de cada R_i se obtienen mediante la proyección del conjunto de DF's de R sobre R_i. Dicha proyección está formada por el conjunto de dependencias X → Y en L+, tal que los atributos de X ∪ Y estén todos contenidos en R_i.

Ejemplo:

- Dada la siguiente relación:
 COCHE (NM, MARCA, TIPO, POTENCIA, COLOR)
 L = {NM → TIPO, TIPO → MARCA, TIPO → POTENCIA, NM → COLOR}
 L+= L ∪ {NM→MARCA, NM→POTENCIA}
- Se tiene la siguiente descomposición $\rho(R_1, R_2)$ para **COCHE**: $\mathbf{R_1}(\mathsf{NM}, \mathsf{TIPO}, \mathsf{COLOR})$ $\mathbf{R_2}(\mathsf{TIPO}, \mathsf{MARCA}, \mathsf{POTENCIA})$
- ¿Qué DF's corresponden a cada R_i?

```
L<sub>1</sub>= { }L<sub>2</sub>= { }
```

Una descomposición ρ= {R₁, R₂,...R_k} del esquema R(T, L) es una descomposición con preservación de dependencias si la unión de las DF's de las relaciones individuales es equivalente al conjunto de DF original. Es decir:

L es <u>equivalente</u> a $\{\cup_{i=(1,k)} L_i\}$, es decir:

$$L^+ = \{ \cup_{i=1..n} L_i \}^+$$

Ejemplo

- **COCHE** (NM, MARCA, TIPO, POTENCIA, COLOR) $L = \{ NM \rightarrow COLOR, TIPO \rightarrow POTENCIA, TIPO \rightarrow MARCA, NM \rightarrow TIPO \}$ $L^{+} = L \cup \{ NM \rightarrow POTENCIA, NM \rightarrow MARCA \}$
- □ **Descomposición 1**: ρ = {R1, R2}

 - **R₂** (TIPO, MARCA, POTENCIA) $L_2 = \{TIPO \rightarrow MARCA, TIPO \rightarrow POTENCIA\}$
- □ ¿La descomposición ρ ={R1, R2} **preserva las dependencias**?

$$\dot{c}\dot{c}$$
 L⁺ = { $\cup_{i=(1,k)}$ L_i}⁺ ??

- **L1** \cup **L2** = {NM \rightarrow TIPO, NM \rightarrow COLOR, TIPO \rightarrow MARCA, TIPO \rightarrow POTENCIA}
- **{L1** \cup **L2}**⁺⁼ {NM \rightarrow TIPO, NM \rightarrow COLOR, TIPO \rightarrow MARCA, TIPO \rightarrow POTENCIA, NM \rightarrow POTENCIA, NM \rightarrow MARCA}

SI conserva las DF's

- Ejemplo

COCHE (NM, MARCA, TIPO, POTENCIA, COLOR)
 L = {NM → COLOR, TIPO → POTENCIA, TIPO → MARCA, NM → TIPO}
 L+ = L ∪ {NM → POTENCIA, NM → MARCA}

Descomposición 2:

- $\begin{array}{lll} & \textbf{R_3} \ (\text{NM, TIPO}) & \textbf{L_3} = \{\text{NM} \rightarrow \text{TIPO}\} \\ & \textbf{R_4} \ (\text{TIPO, POTENCIA, COLOR}) & \textbf{L_4} = \{\text{TIPO} \rightarrow \text{POTENCIA} \} \\ & \textbf{R_5} \ (\text{TIPO, MARCA}) & \textbf{L_5} = \{\text{TIPO} \rightarrow \text{MARCA}\} \\ \end{array}$
- □ ¿La descomposición ρ ={R₃, R₄, R₅} **preserva las dependencias**?

$$\ddot{c}$$
 $L^+ = \{ \cup_{i=(1,k)} L_i \}^+ ??$

- $L_3 \cup L_4 \cup L_5 = \{NM \rightarrow TIPO, TIPO \rightarrow POTENCIA, TIPO \rightarrow MARCA \}$
- $\{L_3 \cup L_4 \cup L_5\}^+ = \{NM \rightarrow TIPO, TIPO \rightarrow POTENCIA, TIPO \rightarrow MARCA, NM \rightarrow POTENCIA, NM \rightarrow MARCA\}$

NO conserva las DF's (pierde NM → COLOR)

Para comprobar que la descomposición de un esquema preserva dependencias hay que comprobar que la unión de las DF's de las relaciones individuales es equivalente al conjunto de DF original :

$$L^{+} = \{ \cup_{(i=1,k)} L_{i} \}^{+}$$

Problema: el tiempo de cálculo de L+ depende exponencialmente del número de dependencias de L. Por ello se propone un algoritmo de test de preservación de dependencias cuyo tiempo de ejecución es una función polinomial del número de dependencias en L.

- **T-operación**: Se define una T-operación sobre el descriptor **Z** respecto del conjunto L de DF's como la sustitución de **Z** por $\mathbf{Z} \cup ((\mathbf{Z} \cap \mathbf{T})^+ \cap \mathbf{T})$ donde el cierre se calcula respecto a L.
- Algoritmo:
 - □ Sea **G** = $\cup_{(i=1,k)} L_i$
 - Considerar cada DF X→Y de L y verificar si X+ respecto de G contiene a Y

$$Z:=X$$
Mientras Z cambie

Para $i:=1$ a \bigcap hacer

 $Z:=Z\cup((Z\cap T_i)^+\cap T_i$

- En cada etapa se modifica el valor del descriptor al aplicar las \mathbf{k} T_i -operaciones (i=1,.,k).
- Si al acabar una etapa no hubiese cambio, el resultado es el cierre Z^+ respecto G (recordar que G es la unión de los L_i).
- Si Y es un subconjunto de Z (Y \subseteq Z), entonces X \rightarrow Y está en G⁺, es decir, si para toda DF X \rightarrow Y \in L, ésta se encuentra en G⁺, (X \rightarrow Y \in G⁺), hay preservación de dependencias y no la habrá en caso contrario.

→ Ejemplo

Dado un esquema R(T, L)

$$T = \{A, B, C, D\}$$

$$L = \{A \rightarrow B, B \rightarrow C, C \rightarrow D, D \rightarrow A\}$$

$$\rho = \{AB, BC, CD\}$$

¿preserva las dependencias?

Es obvio que las dependencias $A \rightarrow B$, $B \rightarrow C$ y $C \rightarrow D$ se conservan en las proyecciones, por lo que será necesario aplicar el Algoritmo para **verificar la conservación de D** \rightarrow **A**

→ Ejemplo

ALGORITMO

- Sea **G** = $\bigcup_{(i=1,k)} L_i$
- Considerar cada DF $X \rightarrow Y$ de L y verificar si X^+ respecto de G contiene a Y

Mientras Z cambie

Desde i := 1 a k hacer

$$Z := Z \cup ((Z \cap T_i)^+ \cap T_i)$$

R(T, L), tal que: $T = \{A, B, C, D\}$ $L = \{A \rightarrow B, B \rightarrow C, C \rightarrow D, D \rightarrow A\}$ $\rho = \{AB, BC, CD\}$

- \square Calcular si se preserva la DF $\mathbf{D} \to \mathbf{A}$
 - Z:= D
 - k = 1

D
$$\cup$$
 ((D \cap AB)⁺ \cap AB) = D
D \cup ((D \cap BC)⁺ \cap BC) = D
D \cup ((D \cap CD)⁺ \cap CD) = D \cup (D⁺ \cap CD)= D \cup (ABCD \cap CD) = CD

■ k = 2

CD
$$\cup$$
 ((CD \cap AB)⁺ \cap AB) = CD
CD \cup ((CD \cap BC)⁺ \cap BC) = CD \cup (ABCD \cap BC)= BCD
BCD \cup (((BCD \cap CD)⁺ CD) = BCD

k = 3

BCD
$$\cup$$
 ((BCD \cap AB)+ \cap AB) = BCD \cup (B+ \cap AB)= BCD \cup (ABCD \cap AB)= ABCD

■ Como $A \subseteq Z$, $D \rightarrow A \in G^+$ se cumple la preservación de dependencias.