

## Estadística Descriptiva<sup>1</sup>

Apellidos:

Nombre:

DNI:

1. (6.5 puntos) El archivo *CitiesQualityOfLiving.RData*<sup>2</sup>, contiene datos referentes a la calidad de vida en 170 ciudades del mundo. Concretamente, continen las variables
  - *city\_name*: Nombre de la ciudad.
  - *DBpedia\_URL*: Dirección del portal DBpedia.
  - *rating*: Puntuación obtenida.
  - (a) (0.5 puntos) Clasificar estadísticamente las variables del archivo.
  - (b) (2.0 puntos) Da la distribución de frecuencias completa de la variable *rating* en grupos que representen a las ciudades con niveles de vida *bajo*  $< 50$ ,  $50 \leq \text{medio} < 96$  y  $96 \leq \text{alto}$ . Representa gráficamente y adecuadamente la variable agrupada.
  - (c) (2.0 puntos) Resume numéricamente la variable *rating* por grupo. ¿Es justificable que el coeficiente de variación disminuya por grupos al aumentar el nivel de vida?
  - (d) (2.0 puntos) Agrupa nuevamente la variable *rating* en tres grupos *bajo*, *medio* y *alto* pero que cada grupo tenga el mismo número de ciudades.
2. (3.5 puntos) Dada la siguiente tabla de Estadísticos resumen, obtén la misma tabla de Estadísticos pero con la variable Tipificada. Justifica todos los valores.

mean	sd	IQR	cv	skewness	kurtosis	0%	25%	50%	75%	100%	n
6.565	2.893134	3.0525	0.4406907	1.166989	0.4408272	3.23	4.5	5.685	7.5525	13.42	20

<sup>1</sup>No se considerarán las respuestas contestadas sin su correspondiente desarrollo.

<sup>2</sup>Descargar desde la url <https://www.dropbox.com/s/5t38ykuxpj22trw/CitiesQualityOfLiving.RData?dl=0>

## Variables Aleatorias<sup>3</sup>

Apellidos:	Nombre:	DNI:
------------	---------	------

1. (3.0 puntos) Un número se elige aleatoriamente al azar dado por la función de densidad:

$$f(x) = \begin{cases} \frac{1}{k} & \text{si } x \in (-1, 1) \\ 0 & \text{en otro caso} \end{cases}$$

- (a) (1.5 puntos) Determinar  $k$  para que sea función de densidad y la varianza.

**Solución:** •  $P(X \in \mathbb{R}) = 1$

$$P(X \in \mathbb{R}) = \int_{-\infty}^{\infty} f(x) dx = \int_{-1}^1 \frac{1}{k} dx = \frac{1}{k} x \Big|_{-1}^1 = \frac{1}{k} (1 + 1) = \frac{2}{k},$$

Por lo tanto,  $\frac{2}{k} = 1 \Leftrightarrow k = 2$

$$\bullet \mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx = \int_{-1}^1 \frac{x}{2} dx = \left[ \frac{x^2}{4} \right]_{-1}^1 = \frac{1}{4} - \frac{1}{4} = 0$$

$$\bullet \sigma^2 = Var(x) = E(X^2) - E(X)^2 = \int_{-\infty}^{\infty} x^2 f(x) dx - 0 = \int_{-1}^1 \frac{x^2}{2} dx = \left[ \frac{x^3}{6} \right]_{-1}^1 = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}$$

□

- (b) (1.5 puntos) Probabilidad de que el primer dígito decimal sea 1. Probabilidad de que el primer dígito decimal de su raíz cuadrada sea 3.

$$\textbf{Solución:} \bullet P(X = ?.1??) = P(X \in (-0.2, -0.1] \cup [0.1, 0.2)) = \int_{-0.2}^{-0.1} f(x) dx + \int_{0.1}^{0.2} f(x) dx = 2 \times \int_{0.1}^{0.2} \frac{1}{2} dx = 2 \times \frac{1}{2} x \Big|_{0.1}^{0.2} = \frac{2}{2} (0.2 - 0.1) = 0.1$$

$$\bullet P(\text{Trunc}(10\sqrt{X}) = 3) = P(10\sqrt{X} \in [3, 4)) = P(\sqrt{X} \in [0.3, 0.4)) = P(X \in [0.09, 0.16)) = \int_{0.09}^{0.16} f(x) dx = \int_{0.09}^{0.16} \frac{1}{2} dx = \frac{1}{2} x \Big|_{0.09}^{0.16} = \frac{1}{2} (0.16 - 0.09) = \frac{0.07}{2} = 0.035.$$

□

2. (7.0 puntos) El número de bits fallidos de escritura en un disco duro de 100Gb sigue una distribución de Poisson de media de 2.

- (a) (1.5 puntos) ¿Cuál es la probabilidad de que en un disco de 500Gb se encuentren menos de 8 errores?

**Solución:** Definimos  $S = X_1 + \dots + X_5$ , con  $X_i$  la v. que representa número de fallos en el trozo de disco duro de 100Gb dado por  $[(i-1) * 100, i * 100)$ Gb.  $X_i \sim \text{Pois}(\lambda = 2)$ , como son intervalos disjuntos las v. son independientes, entonces  $S \sim \text{Pois}(\lambda = 2 * 5 = 10)$

$$P(S < 8) = P(S \leq 7) = \text{ppois}(7, \text{lambda} = 10) = 0.2202206$$

□

- (b) (2.5 puntos) Si dividimos el disco de 500Gb en 5 zonas de 100Gb, ¿cuál es la probabilidad de que en al menos tres zonas se tengan menos de 3 errores?

**Solución:** Definimos  $Y = I_{\{X_1 < 3\}} + I_{\{X_2 < 3\}} + \dots + I_{\{X_5 < 3\}}$ , es decir, contamos el número de éxitos ( $X < 3$ ) en 5 (pruebas). Como  $X_i$  son independientes, tenemos pruebas independientes. Dado que  $P(X_i < 3) = P(X_i \leq 2) = \text{ppois}(2, \text{lambda} = 2) = 0.6766764$ , tenemos que:

$$Y \sim \text{Bi}(5, 0.6766764)$$

y

$$P(Y \geq 3) = 1 - P(Y \leq 2) = 1 - \text{pbinom}(2, \text{size} = 5, \text{prob} = 0.6766764) = 0.8047267$$

□

<sup>3</sup>No se considerarán las respuestas contestadas sin su correspondiente desarrollo.

- (c) (3.0 puntos) Consideremos discos duros de 10Tb, ¿cuál es la probabilidad de que se observen más de 190 errores? Dar la probabilidad exacta y la probabilidad aproximada por la distribución normal teniendo en cuenta que  $\text{Var}(\text{Pois}(\lambda)) = \lambda$ .

**Solución:** Sea  $S$ = número de errores en 10Tb, entonces siguiendo el apartado a)  $S = X_1 + \dots + X_{100} \sim \text{Pois}(\lambda = 2 * 100)$

- (Probabilidad Exacta)  $P(S > 190) = 1 - \text{ppois}(190, \text{lambda} = 200) = 0.7470674$
- (Probabilidad Aprox.) Usando el T.C.L.  $S \approx \tilde{S} \sim N(\lambda, \sqrt{\lambda}) = N(200, \sqrt{200})$ , por lo tanto:

$$P(S > 190) \approx 1 - P(\tilde{S} \leq 190 + 0.5) = 1 - \text{pnorm}(190.5, \text{mean} = 200, \text{sd} = \text{sqrt}(200)) = 0.749129$$

□