

Estadística

Apellidos:	Nome:	DNI:
------------	-------	------

- (3 puntos) El archivo adjunto *datos.metals.txt*¹, contiene datos de contaminación de diferentes metales pesados (en ppm) en diferentes localizaciones geográficas en formato UTM (columnas X,Y). Asociado a cada localización aparece la denominación del lugar en la recogida del dato. Para este conjunto de datos:
 - Clasificar estadísticamente las variables *Zona*, *X*, *Y*, *Metal1*, *Metal2*.
 - Para la v. *Metal1*, los valores mayores de 200 son producto de un error de cálculo y deben ser divididos por 10. Dar la distribución completa de frecuencias agrupando la distribución en intervalos con puntos de corte (0,10,20,30,40,50,200).
 - Calcular la media muestral y la mediana con la variable agrupada y sin agrupar.
 - Dar un resumen numérico completo de la variable *Metal1* para la zona *Lloderó*. Comenta los resultados obtenidos
 - Compara con un diagrama de cajas los valores de la v. *Metal1* en las zonas *Lloderó*, *ALV*, *Praia*. Extrae conclusiones.
- (2 puntos) Consideremos un sistema electrónico que consta de diez componentes que funcionan independientemente teniendo cada uno una probabilidad de fallo de 0.05.
 - Calcula la fiabilidad del sistema (probabilidad de que el sistema funcione correctamente). El sistema funciona correctamente si funcionan todas sus componentes.

Solución: Sea $X = \text{'Número de componentes del sistema que no funcionan'} \sim Bi(10, p = 0.05)$.

$$P(X = 0) = \binom{10}{0} p^0 (1 - p)^{10} = 0.95^{10} = 0.5987369 \quad (1)$$

□

- Si para aumentar la fiabilidad del sistema, se conectan en paralelo dos sistemas iguales al descrito, calcula la fiabilidad del nuevo sistema.

Solución: Sean A_1, A_2 la representación de que funciona el 1er y 2º sistema, respectivamente. La probabilidad pedida es

$$P(A_1 \cup A_2) = P(A_1) + P(A_2) - P(A_1 \cap A_2) = 0.5987369 + 0.5987369 - 0.5987369 * 0.5987369 = 0.8389879 \quad (2)$$

□

- (2.5 puntos) El lenguaje de programación *gfortran* dispone de una rutina *rand()* que devuelve números pseudo-aleatorios entre 0 y 1, representando una v.a. continua con función de densidad:

$$f(x) = \begin{cases} 1 & \text{cuando } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

- Calcular la $P(X > 0.75 \cup X \leq 0.25)$.

Solución: $\text{punif}(0.75, \text{min}=0, \text{max}=1) - \text{punif}(0.25, \text{min}=0, \text{max}=1) = 0.5$

□

- Se desea obtener números enteros de 1 al 10 y se define para ello la siguiente v.a. $Y = \text{Parte_Entera}(10 * X) + 1$. Dar los posibles valores de la variable Y y la probabilidad de cada uno de ellos.

¹Descargar desde la url <https://dl.dropboxusercontent.com/u/29008031/datos.metals.txt>

Solución: La variable Y toma valores enteros (por definición) desde 1 hasta 10. Sus probabilidades son:

$$P(Y = 1) = P(0 < X < 1) = \frac{1}{10},$$

$$P(Y = i) = P(i - 1 \leq X < i) = \frac{1}{10}, \text{ para } i = 2, \dots, 10$$

□

4. (2.5 puntos) Desde un laboratorio con 20 terminales se imprime en una misma impresora. La tasa de envío de documentos a imprimir desde un terminal es una *Poisson* ($\lambda = 3$) por unidad de tiempo. Suponiendo independencia, responder razonadamente:

- a) ¿Cuál es la probabilidad de que un terminal de cualquiera de los 20 envíe más de 2 trabajos?

Solución: Sea $X_1 = \text{n}^\circ \text{ de documentos enviados desde un terminal} \sim \text{Pois}(\lambda = 3)$

$$P(X_1 > 2) = 1 - \text{ppois}(2, 3) = 0.5768099$$

Sea $Y = \text{n}^\circ \text{ de terminales que envían más de 2 trabajos} \sim \text{Bi}(20, 0.5768099)$

$$P(Y = 1) = \text{dbinom}(1, \text{size} = 20, \text{prob} = 0.5768099) = \binom{20}{1} 0.5768099^1 (1 - 0.5768099)^{19} = 9.252033e - 07$$

□

- b) ¿Y si fuesen 100 terminales? Responder usando y sin usar la aproximación normal con la corrección de continuidad.

Solución: Sea $Y = \text{n}^\circ \text{ de terminales de 100 que envían más de 2 trabajos} \sim \text{Binomial}(n = 100, p = 0.5768099)$

$$P(Y=1) = \text{dbinom}(1, 100, 0.5768099) = 6.138286e-36$$

Ahora $Y \sim \text{Binomial}(n = 100, p = 0.5768099) \approx N(100 * 0.5768099, \sqrt{100 * 0.5768099 * (1 - 0.5768099)})$, por lo tanto:

$$P(Y = 1) \approx P(1 - 0.5 \leq \tilde{Y} < 1 + 0.5) = \text{pnorm}(1.5, 100 * 0.5768099, \text{sqrt}(100 * 0.5768099 * (1 - 0.5768099))) - \text{pnorm}(0.5, 100 * 0.5768099, \text{sqrt}(100 * 0.5768099 * (1 - 0.5768099))) = 2.629516e - 30$$

□

Estatística - Variables Aleatorias

Apellidos:	Nome:	DNI:
------------	-------	------

1. (3 puntos) La función de densidad de la v.a. X de Epanechnikov absolutamente continua es:

$$f(x) = \begin{cases} k(1-x^2) & \text{si } x \in (-1, 1) \\ 0 & \text{en otro caso} \end{cases}$$

- a) Determinar k para que sea función de densidad. Obtener la función de distribución.

Solución: $P(X \in \mathbb{R}) = 1$

$$P(X \in \mathbb{R}) = \int_{-\infty}^{\infty} f(x) dx = \int_{-1}^1 k(1-x^2) dx = k \left(x - \frac{1}{3}x^3 \right) \Big|_{-1}^1 = k \left(1 - \frac{1}{3} \right) - k \left(-1 + \frac{1}{3} \right) = k \left(1 - \frac{1}{3} + 1 - \frac{1}{3} \right) = k \left(2 - \frac{2}{3} \right) = k \frac{4}{3},$$

por lo tanto, $\frac{4k}{3} = 1 \Leftrightarrow k = \frac{3}{4}$ □

- b) Calcular dos medidas de tendencia central distintas.

Solución: $\mu = E(X) = \int_{-\infty}^{\infty} xf(x) dx = \frac{3}{4} \int_{-1}^1 x(1-x^2) dx = 0$

Mediana=0, porque la función de densidad es simétrica con respecto al 0, i.e. $f(x) = f(-x)$. □

- c) Calcular la probabilidad de que la v. X tome valores en el intervalo $(-0.75, 0.5)$ condicionado a que X toma valores negativos.

Solución: $P(X \in (-0.75, 0.5) | X < 0) = \frac{P(X \in (-0.75, 0.5) \cap X < 0)}{P(X < 0)} = \frac{P(X \in (-0.75, 0))}{P(X < 0)} = \frac{\int_{-0.75}^0 f(x) dx}{\int_{-1}^0 f(x) dx} = \frac{\int_{-0.75}^0 \frac{3}{4}(1-x^2) dx}{\int_{-1}^0 \frac{3}{4}(1-x^2) dx}$

$$\frac{\frac{3}{8} \left(x - \frac{1}{3}x^3 \right) \Big|_{-0.75}^0}{\frac{3}{8} \left(x - \frac{1}{3}x^3 \right) \Big|_{-1}^0} = \frac{\frac{3}{8} \left(0 + 0.75 - \frac{1}{3}0.75^3 \right)}{\frac{3}{8} \left(0 + 0.75 - \frac{1}{3}0.75^3 \right)} = \frac{\frac{3}{8} \left(0.75 - \frac{0.421875}{3} \right)}{\frac{3}{8} \left(0.75 - \frac{0.421875}{3} \right)} = 0.2285156$$
 □

2. (3 puntos) Si $X \sim N(0.5, 2)$, calcula,

- a) $P(-0.5 < X < 2) =$

Solución: $P(-0.5 < X < 2) = P(X < 2) - P(X < -0.5) = P\left(N(0, 1) < \frac{2-0.5}{\sqrt{2}}\right) - P\left(N(0, 1) < \frac{-0.5-0.5}{\sqrt{2}}\right) = P(N(0, 1) < 0.75) - P(N(0, 1) < -0.5) = (1 - 0.2266) - P(N(0, 1) > 0.5) = 0.7734 - 0.3085 = 0.4649$. □

- b) El valor de a que verifica $P(X > a) = 0.95$. Llega al valor de a usando las funciones de R relacionadas con la Normal con y sin los argumentos $mean=0, sd=1$.

Solución:

El cuantil 0.05, $x_{0.05}$, verifica que: $P(X < x_{0.05}) = 0.05$, y aplicando el complementario tenemos el valor de a . Tipificando y resolviendo obtenemos que:

$P\left(N(0, 1) < \frac{x_{0.05}-0.50}{\sqrt{2}}\right) = 0.05$. El cuantil de la normal 0.5 es negativo porque su probabilidad asociada es menor que 0.5. Aplicando simetría con respecto al cero y buscando en las tablas el valor 0.05 obtenemos que:

$$-\frac{x_{0.05}-0.50}{\sqrt{2}} = 1.645, \text{ resolviendo, } x_{0.05} = 0.50 - 2 * 1.645 = -2.79.$$
 □

3. (4 puntos) Sea X una variable aleatoria distribuida normalmente con media 50 y desviación estándar 4, calcula:

- a) $P(X < 40)$, y el intervalo más pequeño que contenga 0.9 de probabilidad.
- b) Se repite de forma independiente 100 veces la v. aleatoria X . ¿Cuál es la probabilidad de que aparezca 60 veces o más el suceso $\{X > 40\}$? Responder usando la aproximación normal con la corrección de continuidad.

a) $P(X < 40) = P\left(\frac{X-50}{4} < \frac{40-50}{4}\right) = P(Z < -2.5) = P(Z > 2.5) = 0.00621$ con $Z \approx N(0,1)$,

y $P(20 < X < 50) = P(X < 50) - P(X < 20) = P\left(\frac{X-50}{4} < \frac{50-50}{4}\right) - P\left(\frac{X-50}{4} < \frac{20-50}{4}\right) = P(Z < 0) - P(Z < -7.5) \approx 0.5 - 0$.

b) $P(a < X < b) = P\left(\frac{a-50}{4} < \frac{X-50}{4} < \frac{b-50}{4}\right) = 0.9$ como la f. de densidad de la distribución normal es simétrica y unimodal con respecto al 0 y creciente hacia el 0, entonces el límite inferior y el superior del intervalo tienen que distar del 0 la misma cantidad, es decir, $\frac{b-50}{4} - 0 = 0 - \frac{a-50}{4}$ y el área está concentrada en torno al cero.

$P\left(Z < \frac{b-50}{4}\right) = 0.95$ es decir el cuantil 0.95 de la distribución $N(0,1)$, $z_{0.95} = 1.645$ y por lo tanto $\frac{b-50}{4} = 1.645$, $b = 50 + 4 * 1.645 = 56.58$, y $a = 43.42$.