Generador de analizadores léxicos Flex

Procesadores de Lenguajes
3º Grado en Informática

Fco. José Ribadas Pena & Víctor M. Darriba Bilbao

Área de Ciencias de la Computación e Inteligencia Artificial

Marzo 2020

Uso de Flex

- Flex: traduce la especificación de un analizador léxico a un programa C que lo implementa
  - Analizador léxico descrito/especificado mediante *expresiones regulares (ERs)*
  - A las ER se les pueden asociar *acciones* (código C)
  - Cada vez que el analizador encuentra una secuencia que encaja con una de las ER, ejecutará la acción asociada

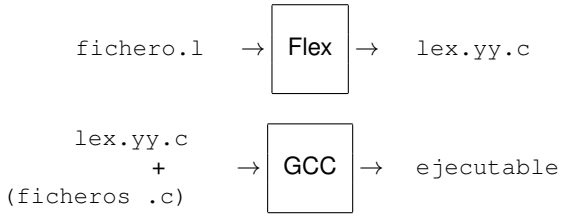

Pasos de compilación

1. Compilar la especificación del analizador y crear el fichero `lex.yy.c` con el código del autómata

```
$ flex fichero.l
```

2. Compilar el analizador C y generar el programa ejecutable
   1. Enlazar con librería de Flex (proporciona implementaciones por defecto para `yywrap()` y `main()`)

```
$ gcc lex.yy.c -lfl
```

   2. Compilar y enlazar con ficheros `.c` del usuario

```
$ gcc lex.yy.c (ficheros .c)
```

      - Usuario proporciona implementaciones para `main()` e `yywrap()`
      - Deberá llamar a la función `yylex()` que reconocerá un TOKEN por cada llamada.

Funcionamiento de Flex

- `lex.yy.c` contiene | tablas del autómata generado
función `int yylex(void)`
- `yylex()` simula el analizador especificado y sirve de interfaz con el código de usuario
  - `yylex()` debe de ser llamada desde el código de usuario

Funcionamiento:

- En cada llamada, `yylex()`:
  1. lee caracteres de la entrada hasta que concuerdan con una ER
  2. almacena el texto que ha concordado en la variable `yytext`
  3. ejecuta la acción (código C) asociada a dicha ER
- Acciones:
  - Puede ser simplemente el procesamiento del texto concordante con la ER para enviarlo de nuevo a la salida.
  - En otras ocasiones podrán suponer la alteración de variables del código de usuario y la devolución a la rutina que llama a `yylex()` (mediante `return`) de un valor numérico que identifique al TOKEN reconocido

Partes de una especificación Flex

- Tres partes separadas por el símbolo `%%`
- Las dos primeras son obligatorias, aunque pueden estar vacías

```
< sección de declaraciones >

%%

< sección de reglas y acciones >

%%

< sección de rutinas de usuario >
```

Sección de declaraciones

- Código C necesario para las acciones asociadas a las ER
  - El código C irá entre `%{` y `%}`, será copiado tal cual al principio de `lex.yy.c`
  - Generalmente serán `#include, #define` y estructuras o variables del código de usuario afectadas por las acciones
- Definición de macros
  - Asocia un ”alias” a expr. regulares usadas en la sección de reglas (mejor legibilidad)
  - En las reglas se referencia ese ”alias” poniéndolo entre llaves

  Definición:
  ```
  LETRA_MAYUSCULA [A-Z]
  DIGITO [0-9]
  ```
  Uso (en reglas): `{LETRA_MAYUSCULA} {DIGITO}`
- Definición de condiciones de arranque (*entornos de reconocimiento*)
  - Entornos dentro de los cuales se podrán reconocer subconjuntos de ERs

  Definición:
  ```
  %start NOMBRE1 NOMBRE2 ... /* alternativamente %s */
  %x NOMBRE1 NOMBRE2 ...
  ```
- Opciones del analizador
  - Se puede usar como alternativa a la linea de comandos de Flex

  Definición: `%option [OPCION1] [OPCION2] ...`

Sección de reglas

- Formato:

```
[ER 1] [acción 1]
....
[ER n] [acción n]
```

- Cada par (`ER`, `acción`) recibe el nombre de regla
  - Flex espera el comienzo de la ER al principio de la línea (no indentar)
  - La ER se separa de la acción con espacios o tabuladores
- Acciones:
  - Si la acción involucra varias instrucciones C en más de una línea, irá entre llaves
  - Si `n` ERs comparten la misma acción se indica con `|` en las `n-1` primeras

```
[ER 1] |
    ...
[ER n] [acción común]
```

  - Si no se especifica ninguna acción, se aplica la acción por defecto `ECHO` (copia el contenido de `yytext` a la salida)
  - La acción vacía (no hacer nada) se escribe como '`;`'
- Por defecto, los caracteres de la entrada que no concuerdan con ninguna ER también se copian a la salida

Sección de rutinas de usuario

En esta sección se puede escribir código C adicional

- Funciones llamadas desde las acciones de las reglas
- En programas sencillos se suele incluir en esta sección las funciones `main()` y `yywrap()` definidas por el usuario

Función `int yywrap()`: se ejecuta cada vez que se alcanza el final de la entrada

- Permite manejar múltiples ficheros de entrada
- Devuelve 1 para indicar que no quedan ficheros de entrada por procesar y que el procesamiento ha terminado (0 en caso contrario)
- Implementación por defecto (opción `-lfl` de `gcc`)

```
int yywrap() {
  return(1);
  }
```

Expresiones regulares en Flex (I)

Expresiones simples:

`c`	el carácter '`c`'
`\a`, `\b`, `\f`, `\n`, `\r`, `\t`, `\v`	símbolos especiales de ANSI-C
`<<EOF>>`	fin de fichero
`.`	cualquier carácter excepto salto de linea ('`\n`')
`[abc]`	cualquier carácter del conjunto ('`a`', '`b`' ó '`c`')
`[^abc]`	cualquier carácter excepto los del conjunto
`[a-z]`	cualquier carácter del rango indicado
`[^a-z]`	cualquier carácter excepto los del rango
`[a-z]{-}[aeiou]`	diferencia de clases de caracteres (consonantes en minúsculas)
`"xxxx"`	la cadena `xxxx` reconocida de forma literal
`"."`	el carácter '`.`'
`{ALIAS}`	expande la ER asociada la macro `ALIAS`

Expresiones regulares en Flex (II)

Operadores (de mayor a menor precedencia):

R+	reconoce 1 ó más repeticiones de R (cierre transitivo)
R*	reconoce 0 ó más repeticiones de R (cierre reflexivo-transitivo)
R?	reconoce 0 ó 1 ocurrencia de R (opcional)
R{n}	reconoce n repeticiones exactas de R
R{n,m}	reconoce de n a m repeticiones de R
(R)	agrupa expresiones regulares
RS	reconoce la concatenación de R y S
R|S	reconoce o R o S
^R	reconoce la expr. R si está al inicio de linea
$R$$	reconoce la expr. R si está al final de linea

Siendo R y S expr. regulares

Expresiones regulares en Flex (III)

R/S	reconoce R sólo si lo que sigue a continuación encaja con S (S define el contexto donde reconocer R)
`<UNO>`R	reconoce R si la condición de arranque `UNO` está activa
`<UNO,DOS>`R	reconoce R si una de las condiciones de arranque `UNO` o `DOS` están activas
`<*>`R	reconoce R si alguna de las condiciones de arranque definidas en el analizador están activas

Modificadores:

`(?a:`R`)`		`i` = R insensible a mayúsculas/minúsculas,
`(?-a:`R`)`	`a,b` $\in$ {`i,s,x`}	`s` = '`.`' incluye el salto de línea ('`\n`')
`(?a-b:`R`)`		`x` = ignora espacios en blanco y comentarios en R

Para leer los operadores como caracteres:

```
(comillas)   "."  "*"  "+"  "?"  "$"  "["  "]"  "("  ")"  "{"  "}"
(escapados)  \.   \*   \+   \?   \$   \[   \]   \(   \)   \{   \}   \"   \\
```

Ambigüedad

Uno de los mayores problemas en el análisis de lenguajes formales

- En Flex:
  - Existencia de varias concordancias simultáneas entre el texto y ERs
- Solución (heredada de Lex):
  - Seleccionar una de las ERs posibles

Mecanismo de resolución de ambigüedades en Flex

1. Si la entrada concuerda con más de una ER se elige la que abarca el mayor núm. posible de caracteres
   - Flex es voraz (greedy) y ese comportamiento **no se puede cambiar**
2. Si más de una ER concuerda con el mayor número de caracteres, se elige la que aparezca primero en la especificación Flex
   - El orden de las reglas puede tener importancia
   - Heurística: escribir primero las reglas con las ERs más específicas

Condiciones de arranque (entornos de reconocimiento) (I)

Usadas para definir mini-analizadores:

- Reglas que se usan sólo cuando se cumplen determinadas condiciones

Se definen en la zona de declaraciones:

- Condiciones de arranque inclusivas (`%start`, `%s`)
  - También permiten usar las reglas no asociadas a ninguna condición de arranque
- Condiciones de arranque exclusivas (`%x`)
  - Sólo permiten usar las reglas asociadas a la condición de arranque

Se cambian en las acciones de las reglas:

- Durante la ejecución del analizador siempre hay una condición activa
- `INITIAL`: condición de arranque por defecto
- `BEGIN`: macro usada para cambiar a otra condición de arranque
  - `BEGIN(INITIAL)` o `BEGIN(0)` sirve para volver al entorno por defecto

Condiciones de arranque (entornos de reconocimiento) (II)

Ejemplo: eliminación de comentarios multilínea en C

- Solución obvia: una expresión regular con la acción vacía

```
"/*"(.|\n)*"*/"     ;
```

  Debido a la voracidad de Flex, funciona “demasiado” bien
  - Elimina todo el texto desde el primer `"/*"` al último `"*/"`
- Una solución mejor: usar una condición de arranque exclusiva

```
%x COMENTARIO    /* exclusiva: no queremos usar otras reglas */
...
%%
...
"/*"             BEGIN(COMENTARIO); /* entramos en modo comentario */
<COMENTARIO>.|\n ;                  /* nos comemos el comentario */
<COMENTARIO>"*/" BEGIN(INITIAL);    /* volvemos al analizador */
...
```

Entrada y salida

Se regula a través de dos variables de tipo puntero a fichero (`FILE *`)

- `yyin`: entrada desde la que el analizador lee caracteres
  - Por defecto la entrada estándar `STDIN` (terminal)
- `yyout`: salida a la que escribe el analizador
  - Por defecto la salida estándar `STDOUT` (terminal)
- Se pueden redireccionar a archivos usando la función de C `fopen()` en el código de usuario (generalmente en el `main()`):

```
yyin = fopen("entrada.txt","r");
yyout = fopen("salida.txt","w");
```

Las funciones de C que podemos usar para escribir en la salida del analizador cambian según a donde apunte `yyout`:

- Si apunta a `STDOUT`, podemos usar `putchar()` o `printf()`
- Si redireccionamos a un archivo, usaremos `fputc()` o `fprintf()`

Otros elementos predefinidos (I)

Variables Flex accesibles desde el código de usuario

- `yytext`: Puntero a una cadena de caracteres que contiene la última cadena de texto que encajó con una ER
  - Por defecto, está declarada como `char *yytext`
  - Su contenido sólo es estable dentro de las reglas y entre llamadas consecutivas a la función `yylex()`
- `yyleng`: Entero con la longitud de la cadena `yytext`

Otros elementos predefinidos (II)

Opciones del analizador

- `case-insensitive`: hace que el analizador ignore mayusculas y minúsculas
- `header-file="[nombre]"`: hace que flex genere un archivo de cabecera en C (`.h`) para el analizador con el nombre indicado
- `outfile="[nombre]"`: el archivo fuente del analizador se llamara `[nombre]`, en lugar de `lex.yy.c`
- `yylineno`: le dice al analizador que guarde el número de línea de la posición actual en la entrada, en la variable global entera `yylineno`
- `yywrap`: hace que `yylex()` omita la llamada a `yywrap()` al llegar al final de la entrada, terminando la ejecución del analizador
- `main`: hace que Flex proporcione una versión por defecto de `main()`, con una llamada a `yylex()`. Esta opción incluye a la opción `yywrap()`
- `c++`: ordena generar el analizador en C++, en lugar de en C.
- `array`: hace que `yytext` sea definida como array, en lugar de como `char *`

Otros elementos predefinidos (III)

Funciones y macros predefinidas

- `REJECT`: Rechaza la concordancia entre la ER actual y el texto almacenado en `yytext` y pasa a la siguiente regla que encaje (si la hay)
- `YY_START`: Devuelve el valor entero correspondiente a la condición de arranque actual
- `yymore()`: Le dice al analizador que en la próxima concordancia con una ER, en lugar de reemplazar el contenido actual de `yytext`, concatene la nueva cadena a la actual
- `yyless(n)`: Devuelve todos los caracteres en `yytext` a la entrada, excepto los *n* primeros
- `unput(c)`: mete el carácter `c` en la posición actual de la entrada
- `input()`: lee el siguiente caracter de la entrada, avanzando una posición en la misma
- `yyterminate()`: termina la ejecución del analizador, devolviendo 0